



CENTRO UNIVERSITÁRIO DA GRANDE DOURADOS

Artur Amadeu Wagner Fidelix

Arquitetura moderna de dados com Airflow, BigQuery e Looker Studio

Trabalho de Conclusão de Curso
apresentado ao Curso de Engenharia de
Software como pré-requisito para
obtenção do título de Bacharel em
Engenharia de Software

Orientador(a): Prof. Msc. Antonio Pires
de Almeida Junior.

Dourados
2025

Sumário

Contextualização.....	2
Glossário.....	3
Coleta de Requisitos.....	4
Definição de Requisitos.....	4
Requisitos de Funcionais.....	4
Requisitos Não Funcionais.....	4
Especificação de Requisitos.....	6
Casos de Uso.....	6
Descrição dos Casos de Uso.....	6
Diagrama Entidade-Relacionamento.....	8
Protótipo de Interfaces.....	11
Painel para Análise de dados.....	11
Referências.....	12

Contextualização

Com o avanço constante da transformação digital, empresas de todos os tamanhos têm se deparado com o desafio de modernizar suas infraestruturas de dados. A necessidade de lidar com volumes cada vez maiores de informações e de extrair insights em tempo real exige soluções que sejam ágeis, seguras e escaláveis. Nesse cenário, as arquiteturas de dados modernas ganham destaque, especialmente aquelas que conseguem integrar ambientes on-premises com serviços em nuvem, combinando o melhor dos dois mundos: controle local e flexibilidade operacional.

De acordo com Marr (2022), organizações orientadas por dados tendem a tomar decisões mais assertivas e a inovar com maior frequência. Ainda assim, muitas empresas encontram barreiras nesse processo de transformação — seja pela complexidade técnica da integração entre sistemas, pela ausência de automação nas rotinas de ETL ou pelos custos envolvidos em migrar totalmente para a nuvem. Essa lacuna mostra a importância de soluções híbridas, que possibilitem uma modernização gradual e financeiramente viável.

Diante desse cenário, este projeto propõe o desenvolvimento de uma arquitetura híbrida de dados que sirva como um modelo acessível para empresas em processo de modernização tecnológica. O Apache Airflow será executado on-prem, via Docker Compose, com a função de orquestrar os fluxos de extração, transformação e carga (ETL) utilizando o conjunto de dados público AdventureWorks, disponibilizado pela Microsoft. Os dados processados serão carregados no Google BigQuery, que atuará como data warehouse em nuvem, e posteriormente disponibilizados em painéis interativos no Looker Studio, simulando relatórios corporativos reais.

Essa proposta busca refletir a realidade de muitas organizações de pequeno e médio porte que ainda mantêm parte de suas operações em sistemas legados ou servidores locais. Para essas empresas, uma arquitetura híbrida oferece a oportunidade de experimentar soluções modernas de dados sem comprometer a continuidade dos seus negócios. Assim, o projeto pretende servir como um exemplo prático de como implementar uma plataforma de dados moderna, automatizada e sustentável, equilibrando eficiência técnica e acessibilidade.

Além de seu valor técnico, o projeto também tem um caráter educativo e exploratório. Ele busca consolidar e aplicar conceitos de engenharia de dados, computação em nuvem e automação de pipelines em um ambiente realista e reproduzível. Dessa forma, o trabalho contribui não apenas para o desenvolvimento profissional na área de dados, mas também para a disseminação de práticas modernas de arquitetura híbrida, ajudando empresas e profissionais a entenderem, na prática, que a modernização é possível de forma planejada, gradual e inteligente.

Glossário

ETL

Extract Transform Load (Extrair, transformar e carregar)

Coleta de Requisitos

Para o levantamento dos requisitos do projeto, foi realizada uma pesquisa exploratória com base em estudos de empresas que estão em processo de modernização de suas infraestruturas de dados, buscando soluções que unam facilidade de implantação, escalabilidade e baixo custo operacional. Essa análise permitiu compreender as principais demandas e desafios enfrentados por organizações que adotam arquiteturas híbridas, integrando ambientes on-premises e serviços em nuvem.

Além disso, foi conduzida uma análise técnica das ferramentas que compõem a arquitetura proposta — Apache Airflow, Google BigQuery e Looker Studio — por meio de documentação oficial e testes práticos. Também foram considerados cenários simulados baseados na base pública AdventureWorks, que representa uma empresa de médio porte com estrutura corporativa realista.

Definição de Requisitos

A partir das respostas obtidas pela aplicação do questionário, foi possível elencar os seguintes requisitos:

Requisitos de Funcionais

- O sistema deve orquestrar pipelines de ETL utilizando o Apache Airflow executado on-premises via Docker Compose.
- O Airflow deve extrair dados da base AdventureWorks (em formato CSV ou SQL Server) e realizar transformações antes da carga.
- O sistema deve carregar os dados transformados para o Google BigQuery.
- O BigQuery deve armazenar os dados de forma estruturada, permitindo consultas analíticas otimizadas.
- O Looker Studio deve consumir os dados do BigQuery e apresentar dashboards com indicadores de negócio.
- O Airflow deve registrar logs de execução e status de cada tarefa do pipeline.
- O usuário deve conseguir executar todo o ambiente on-prem com um único comando via Docker Compose.

Requisitos Não Funcionais

- O ambiente deverá ser modular, permitindo substituição de componentes sem reconfiguração completa.
- O tempo médio de execução dos pipelines deverá ser inferior a 24 horas em ambiente de teste.
- A visualização dos dashboards deve ser responsiva e acessível via navegador.

- A arquitetura deverá seguir boas práticas de data governance e versionamento de código.

Especificação de Requisitos

A seção a seguir apresenta os requisitos e os diagramas de implementação do sistema.

Casos de Uso

Considerando o critério de classificação por responsabilidade e campo de atuação na arquitetura híbrida sugerida, detectaram-se dois grupos principais de casos de uso: os vinculados ao Engenheiro de Dados e os desempenhados pelo Analista de Dados. O Engenheiro de Dados responde pelas tarefas ligadas à criação e gestão dos pipelines, como configurar fluxos de ETL, programar execuções automáticas e acompanhar o desempenho do pipeline no Airflow. Já o Analista de Dados atua diretamente no Looker Studio, realizando a análise dos gráficos, criação de dashboards e elaboração de relatórios a partir dos dados carregados no BigQuery.

Ao contrário de um sistema convencional em que todos os perfis utilizam o mesmo ambiente, neste projeto cada usuário atua em uma plataforma específica: o Engenheiro de Dados trabalha apenas na plataforma do Airflow, enquanto o Analista opera exclusivamente nas camadas de visualização e análise. Dessa forma, não existe sobreposição de permissões entre os usuários, pois cada grupo de casos de uso corresponde a funções particulares do seu papel na arquitetura de dados. O diagrama final reflete essa separação clara entre os fluxos de responsabilidade, destacando como cada ator contribui para o funcionamento completo da solução de dados proposta.




Figura 1 – Diagrama de caso de uso da Arquitetura moderna de dados.

Descrição dos Casos de Uso

Caso de uso: Análise de dados

Ator: **Analista de dados**

Descrição: Ao acessar o ambiente de visualização no Looker Studio, o Analista de Dados inicia seu trabalho selecionando os dashboards disponíveis ou criando novos painéis a partir das tabelas carregadas no BigQuery. Assim que identifica a necessidade de análise, ele escolhe os gráficos ou métricas desejadas e configura filtros, períodos e dimensões relevantes para o contexto empresarial. Após ajustar a visualização, o sistema atualiza automaticamente os dados, permitindo ao analista interpretar tendências, comparar indicadores e gerar insights. Por fim, o Analista pode compilar essas informações em

relatórios personalizados e compartilhá-los com a equipe, recebendo uma confirmação do sistema ao salvar ou publicar o dashboard.

Caso de uso: Engenharia de dados

Ator: Engenheiro de dados

Ao acessar o ambiente do Airflow, o Engenheiro de Dados inicia configurando o pipeline responsável por extrair e transformar os dados da base AdventureWorks. Ele seleciona ou cria um novo DAG, define as tarefas necessárias e ajusta parâmetros como conexões, caminhos, dependências e variáveis de execução. Após configurar o fluxo, o engenheiro agenda sua execução automática, estabelecendo a periodicidade adequada às necessidades da empresa. Durante a operação, o sistema exibe o status de cada tarefa em tempo real, permitindo ao Engenheiro monitorar falhas, reprocessar etapas e validar a integridade do pipeline. Ao final, o Airflow registra o sucesso da execução e disponibiliza logs detalhados para auditoria e acompanhamento contínuo.

Diagrama Entidade-Relacionamento

O diagrama Entidade-Relacionamento apresenta as tabelas de fato e dimensão utilizadas no projeto e como elas se relacionam entre si. Ele fornece uma visão clara da estrutura dos dados que será utilizada no pipeline e nas análises.




Figura 2 – Diagrama de Entidade - Relacionamento para o AdventureWorks banco utilizado de exemplo na arquitetura de dados.

- A tabela DimDate foi criada para armazenar informações de datas utilizadas nas análises do data warehouse. Ela fornece a chave de data e a data completa em formato alternativo, permitindo que fatos como vendas sejam relacionados ao calendário corporativo;
- A tabela DimCustomer representa os clientes da empresa, contendo informações pessoais básicas e a relação com a região geográfica de cada cliente. Ela é usada para análises de vendas por perfil de consumidor e por localização;
- A tabela DimProductSubcategory agrega produtos em grupos intermediários, conectando cada subcategoria à sua categoria principal. Isso facilita análises hierárquicas de produtos em níveis mais agrupados;
- A tabela DimSalesTerritory contém regiões comerciais definidas pela empresa. Ela apoia a análise de vendas por território e a avaliação de desempenho das equipes ou regiões;
- A tabela DimPromotion registra informações sobre promoções ativas, permitindo identificar o impacto de campanhas promocionais nos resultados de vendas;
- A tabela DimCurrency armazena o tipo de moeda utilizada nas transações. Ela permite converter e analisar vendas em diferentes moedas utilizando padrões consistentes;
- A tabela FactInternetSales concentra os registros de vendas realizadas pela loja virtual da empresa. Ela relaciona produtos, clientes, datas e promoções, armazenando métricas como valor de venda para análises de performance do e-commerce;
- A tabela DimEmployee registra os funcionários da área comercial responsáveis por vendas e relacionamento com territórios. Ela permite avaliar o desempenho de equipes e vendedores;
- A tabela DimReseller representa os revendedores parceiros da empresa, com informações como nome e localização geográfica. Ela serve de referência para análises de vendas indiretas;
- A tabela FactResellerSales contém as vendas feitas por meio de revendedores. Ela registra as mesmas métricas de vendas da tabela fact

principal, porém vinculadas a revendedores, funcionários e territórios, permitindo análises específicas desse canal de vendas;

- A tabela DimProductCategory armazena as categorias de produtos, o nível mais alto da hierarquia. Ela possibilita análises amplas de vendas por grupos gerais de produtos; e
- A tabela DimGeography representa informações geográficas, como cidade e território associado. Ela é utilizada para analisar vendas por região e para ligar clientes e revendedores às áreas em que atuam.

Protótipo de Interfaces

A presente seção demonstrará os protótipos das telas do sistema.

Painel para Análise de dados

O protótipo a seguir mostra um das telas do caso de uso “Análise de dados”, que serve para disponibilizar os dados para o analista:



Figura 3 – Protótipo de tela “Análise de dados”.

Referências

MARR, Bernard. Data Strategy: How to Profit from a World of Big Data, Analytics and AI. 2. ed. Kogan Page, 2022.

KIMBALL, Ralph; ROSS, Margy. The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling. 3. ed. Wiley, 2013.

APACHE AIRFLOW. Airflow Documentation. Apache Software Foundation. Disponível em: <https://airflow.apache.org/>.

GOOGLE CLOUD. BigQuery Documentation. Google. Disponível em: <https://cloud.google.com/bigquery>

GOOGLE CLOUD. Looker Studio Documentation. Google. Disponível em: <https://lookerstudio.google.com/>